PROPOSAL GEMASTIK XIX

"MoodIn: Smart Mirror untuk Klasifikasi Mood Berbasis *Graph Convolutional Network* dan *remote Photoplethysmography* sebagai *Personal Wellness Coach*"

VisionaryX :

Anggota :

Jeremia Christ Immanuel Manalu	5023231017
Tanuhita Setya Dhanurendra	5023231026
Nozomi Crystalle Padilla Malle	5023241046

Dosen Pembimbing :

Nada Fitrieyatul Hikmah, S.T., M.T.

Institut Teknologi Sepuluh Nopember

Surabaya

2026

ABSTRAK

DAFTAR ISI

ABSTRAK i
BAB I PENDAHULUAN 2
1.1. Latar Belakang 2
1.2. Rumusan Masalah 3
1.3. Tujuan Pengembangan Alat 4
1.4. Urgensi dan Manfaat 4
1.5. Dampak Sosial dan Masyarakat (SDGs) 5
BAB II METODE DASAR PENGEMBANGAN KARYA 6
2.1. Arsitektur Sistem 6
2.2. Model Dimensional Mood: Russell's Circumplex Model of Affect 6
2.3. Ekspresi Wajah sebagai Representasi Mood 9
2.4. Remote Photoplethysmography (rPPG) untuk klasifikasi Mood 10
2.5. Graph Convolutional Network untuk Klasifikasi Mood Multimodal 11
2.6. Internet of things untuk Integrasi Sistem Wellness 12
BAB III DESAIN PURWARUPA 13
3.1. Spesifikasi Prototipe 13
3.2. Model 3D Desain 15
3.3. Prototipe Progres 17
BAB IV ANALISIS FUNGSIONAL 19
4.1. Prinsip Kerja Sistem 19
4.2. Analisis Fungsional 19
4.3. Alur Kerja Sistem 20
4.4. Kinerja/Performansi 20
BAB V RENCANA IMPLEMENTASI DAN PERKEMBANGAN PENGERJAAN 21
5.1. Tahapan Implementasi 21
5.2 Lokasi Implementasi Awal 22
DAFTAR PUSTAKA 23
LAMPIRAN 26

BAB I
PENDAHULUAN

1.1. Latar Belakang

Kesehatan mental merupakan salah satu tantangan pembangunan manusia yang paling mendesak di Indonesia saat ini. Survei Kesehatan Indonesia (SKI) 2023 yang dilaksanakan Kementerian Kesehatan RI terhadap sekitar 345 ribu rumah tangga di 38 provinsi mencatat prevalensi depresi nasional sebesar 1,4%, dengan kelompok usia 15–24 tahun (Generasi Z) menunjukkan prevalensi tertinggi dibanding kelompok usia lain, yaitu 2% [1]. Yang lebih mengkhawatirkan, pada kelompok anak muda pengidap depresi ini, survei yang sama mencatat bahwa 61% di antaranya pernah berpikir untuk mengakhiri hidup dalam satu bulan terakhir saat survei dilakukan, namun hanya 10,4% dari kelompok berisiko tinggi ini yang benar-benar mencari pengobatan formal [1], [2].

Riskesdas 2018 memakai SRQ-20 atau self-report screening umum, sedangkan SKI 2023 memakai MINI yang merupakan wawancara terstruktur klinis untuk depresi spesifik. Studi re-analisis oleh Zhafirah & Hastono (Universitas Indonesia) bahkan menunjukkan bahwa saat SKI 2023 dianalisis ulang memakai instrumen SRQ-20 yang sama dengan Riskesdas 2018, prevalensi masalah kesehatan jiwa turun menjadi 2,0%, jauh dari 9,8%, bukti bahwa perubahan metodologis, bukan semata perbaikan kondisi riil, banyak berkontribusi pada disparitas angka ini [3].

Terlepas dari perbedaan angka absolut antarsurvei, satu temuan konsisten pada keduanya adalah: kelompok usia produktif-muda menanggung beban gangguan mood tertinggi namun memiliki tingkat pencarian bantuan (*help-seeking*) yang paling rendah. Kesenjangan ini berbanding terbalik dengan meningkatnya keterbukaan wacana kesehatan mental di ruang digital. Data internal Google Indonesia yang dipublikasikan awal 2021 mencatat kenaikan volume pencarian kata kunci terkait kesehatan mental sebesar 70% dan *self-care* sebesar 45% pada masa pandemi dibandingkan periode sebelumnya [4], dan studi akademik lain menunjukkan tren pencarian daring terkait gejala gangguan jiwa berkorelasi dengan kondisi psikologis populasi secara agregat, menjadikan minat pemantauan mandiri ini sebagai sinyal yang terukur, bukan sekadar anekdot [5]. Meningkatnya keterbukaan ini sayangnya belum diikuti oleh akses layanan yang memadai, jumlah psikolog klinis yang terbatas, stigma sosial, dan biaya terapi tetap menjadi penghalang struktural utama.

Instrumen swa-pantau (*self-monitoring*) yang umum digunakan saat ini, jurnal mood manual maupun kuesioner psikometri seperti PANAS atau DASS-21, pada dasarnya adalah bentuk *retrospective self-report* yang rentan terhadap *recall bias*: distorsi ingatan di mana

kondisi afektif seseorang saat mengisi laporan memengaruhi cara ia mengingat pengalaman sebelumnya [6]. Literatur *ecological momentary assessment* (EMA) turut mencatat bahwa metode retrospektif ini memiliki *response burden* tinggi karena bergantung pada kesediaan dan kejujuran pengguna mengisi laporan secara konsisten setiap hari, sehingga kepatuhan jangka panjang cenderung menurun [7]. Alternatif berbasis sensor *wearable* (mis. jam tangan pintar untuk HRV) dapat menyediakan data fisiologis yang lebih objektif, namun sifatnya yang harus dikenakan terus-menerus membuatnya kurang sesuai untuk pemantauan pasif dalam rutinitas privat harian, seperti saat bercermin di kamar mandi atau kamar tidur.

Bercermin adalah salah satu dari sedikit rutinitas yang hampir seluruh individu lakukan setiap hari tanpa perlu diingatkan, menjadikannya titik kontak alami (*zero-friction touchpoint*) untuk menyisipkan mekanisme skrining mood tanpa menambah beban kognitif atau waktu tambahan. Berdasarkan observasi inilah, tim VisionaryX mengembangkan MoodIn, sebuah *smart mirror* yang mengklasifikasikan mood harian pengguna secara *contactless* melalui kombinasi analisis ekspresi wajah berbasis *Graph Convolutional Network* (GCN) dan sinyal fisiologis *remote-photoplethysmography* (rPPG), untuk berfungsi sebagai *personal wellness coach* yang memberikan umpan balik preventif sebelum kondisi psikologis berkembang menjadi gangguan yang lebih berat.

1.2. Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah yang diangkat dalam proyek ini adalah:

1. Bagaimana merancang sistem *smart mirror* yang mampu mengklasifikasikan mood harian pengguna secara *non-intrusive* dan *real-time*, dengan menggabungkan analisis ekspresi wajah dan sinyal fisiologis tanpa kontak?
2. Bagaimana merepresentasikan mood ke dalam kerangka dimensional (v*alence–arousal*) menggunakan *Graph Convolutional Network*, sehingga keluaran klasifikasi lebih kaya informasi dan lebih tahan terhadap keterbatasan model kategori emosi diskrit yang kaku?
3. Bagaimana merancang mekanisme fusi multimodal yang menggabungkan fitur geometris wajah (*Action Units*) dan fitur fisiologis (HRV/BRV dari rPPG) ke dalam satu ruang representasi mood yang konsisten?
4. Bagaimana merancang arsitektur IoT (*edge-to-cloud*) yang memungkinkan pelacakan tren mood mingguan dan pemberian rekomendasi intervensi personal, tanpa mengorbankan privasi data biometrik wajah pengguna?

1.3. Tujuan Pengembangan Alat

Tujuan dari pengembangan MoodIn adalah untuk:

1. Merancang perangkat keras dan lunak *smart mirror* yang dapat mengakuisisi dan memproses video wajah pengguna secara *real-time* untuk keperluan skrining mood harian.
2. Mengimplementasikan arsitektur GCN yang memetakan geometri *Facial Action Units* ke ruang dimensional valence–arousal, alih-alih ke kategori emosi diskrit semata.
3. Membangun mekanisme *late fusion* yang menggabungkan fitur biomekanis wajah dan fitur fisiologis rPPG (HRV/BRV) menjadi satu vektor representasi mood yang dipersonalisasi terhadap baseline pengguna.
4. Mengintegrasikan sistem klasifikasi ke dalam arsitektur IoT (MQTT *gateway*, basis data *time-series* di cloud) yang menyajikan tren mood mingguan dan rekomendasi *micro-intervention* melalui aplikasi pendamping, sesuai rancangan yang dibuat.

1.4. Urgensi dan Manfaat

Tingginya beban gangguan mood pada kelompok usia produktif-muda di Indonesia [1], [2], diperparah oleh rendahnya tingkat pencarian bantuan formal pada kelompok yang justru paling berisiko, menciptakan celah yang tidak tertangani oleh instrumen skrining konvensional. Kuesioner psikometri bersifat retrospektif dan rentan bias ingatan [6], [7]; sensor *wearable* bersifat intrusif untuk pemantauan jangka panjang; sementara meningkatnya minat masyarakat terhadap pemantauan diri [4], [5] belum diimbangi oleh alat ukur yang objektif, murah, dan mudah diintegrasikan ke rutinitas harian. Oleh karena itu, dibutuhkan sistem skrining mood yang bekerja secara pasif, non-invasif, dan mampu menangkap sinyal afektif majemuk (wajah dan fisiologis) secara simultan, sebuah kombinasi yang belum banyak diimplementasikan pada perangkat konsumen di Indonesia.

Adapaun manfaat dari pengembangan MoodIn ini adalah sebagfai berikut:

1. Memungkinkan skrining mood harian secara *contactless* dan *zero-friction*, terintegrasi ke rutinitas bercermin tanpa memerlukan kuesioner atau sensor tempel.
2. Menyediakan representasi mood yang lebih kaya secara dimensional (valence–arousal) dibanding label emosi diskrit semata, sehingga lebih relevan untuk pelacakan tren jangka panjang.
3. Mendukung deteksi dini pergeseran mood sebelum berkembang menjadi gangguan yang lebih berat, melalui rekomendasi *micro-intervention* dan pelacakan tren mingguan.

4. Menjaga privasi pengguna dengan memproses data biometrik wajah secara lokal (edge computing di Raspberry Pi), tanpa mengirimkan citra wajah mentah ke cloud.

1.5. Dampak Sosial dan Masyarakat (SDGs)

Inovasi MoodIn berkontribusi pada tujuan Sustainable Development Goals (SDGs), di antaranya:

a. SDG 3: Good Health and Well-Being
   - MoodIn membantu pengguna menjaga kesehatan mental sejak dini dengan mendorong self-awareness melalui perubahan mood yang terdeteksi.
   - Dengan mengutamakan prinsip *contactless*, inovasi ini meningkatkan akses terhadap pemantauan kesehatan mental pengguna secara rutin tanpa mengganggu aktivitas sehari-hari.
   - Meningkatkan kepercayaan pengguna terhadap sistem sehingga pemantauan kesehatan mental lebih aman dan berkelanjutan.

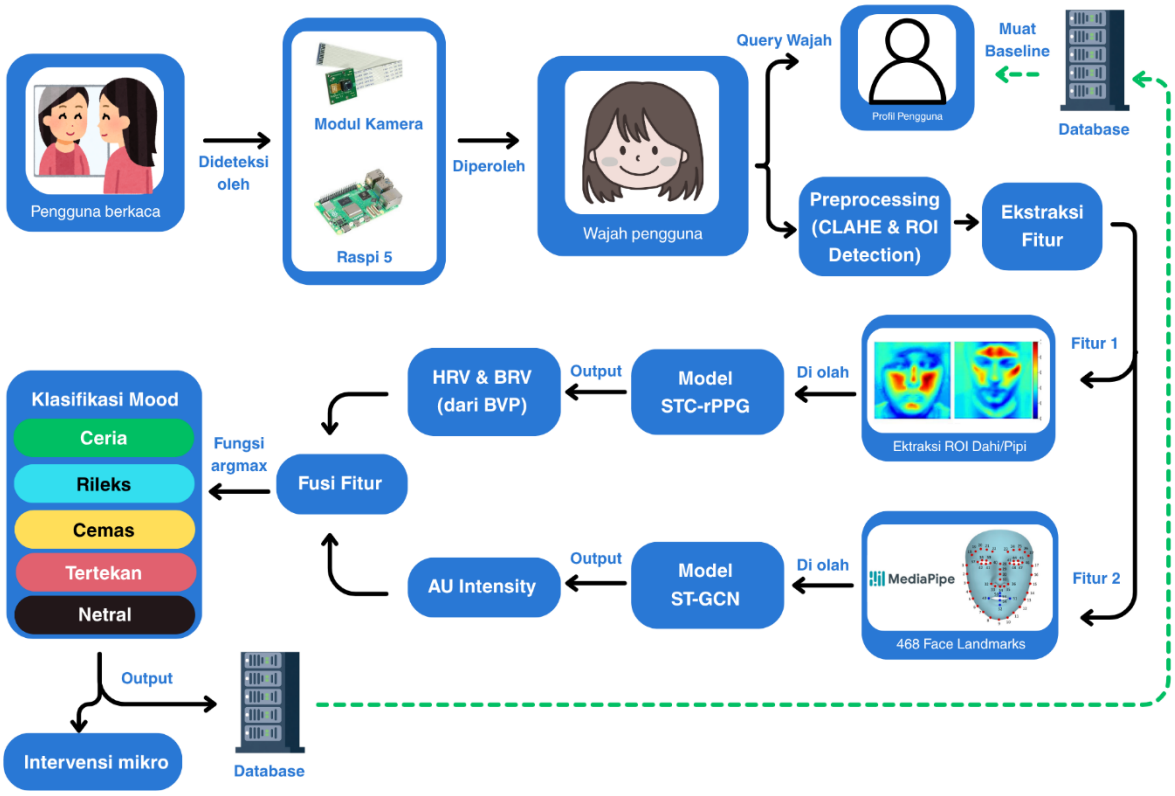
b. SDG 4: Quality Education
   - MoodIn meningkatkan kesadaran pengguna akan pentingnya menjaga kesehatan mental sebagai bagian dari gaya hidup sehat.
   - Inovasi ini mendorong terbentuknya kebiasaan refleksi diri dan pemantauan kondisi emosional secara mandiri.

c. SDG 9: Industry, Innovation and Infrastructure
   - MoodIn mengintegrasikan teknologi Smart Mirror, Graph Convolutional Network (GCN), dan edge computing dalam satu sistem pemantauan kesehatan mental.
   - Dengan pemrosesan data secara lokal (*edge computing*), MoodIn menghadirkan solusi smart healthcare yang menjaga privasi pengguna tanpa mengurangi kinerja sistem.

BAB II
METODE DASAR PENGEMBANGAN KARYA

2.1. Arsitektur Sistem

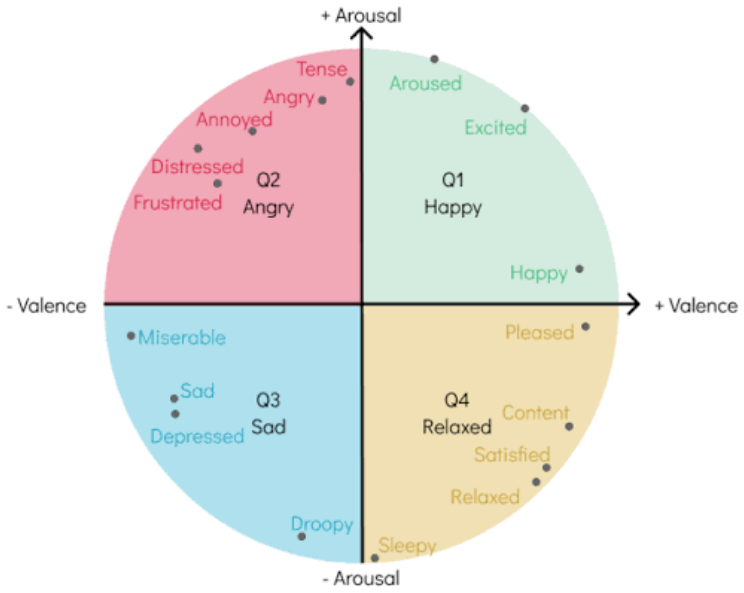
Gambar 1 berikut merepresentasikan alur sistem MoodIn, mulai dari proses akuisisi wajah oleh Unit Edge, ekstraksi fitur, hingga output yang dihasilkan MoodIn, berupa intervensi mikro dan mood tracker.



Gambar 1. Arsistektur Sistem MoodIn

2.2. Model Dimensional Mood: Russell's Circumplex Model of Affect

Pemilihan kerangka representasi mood merupakan keputusan desain yang menentukan seluruh arsitektur hilir MoodIn. Terdapat dua paradigma utama dalam literatur *affective computing*: model kategorikal, misalnya enam emosi dasar Ekman yakni, senang, sedih, marah, takut, jijik, terkejut, dan model dimensional, yang paling banyak diadopsi dalam bentuk *circumplex model of affect* yang diperkenalkan oleh Russell (1980) [8]. Model ini memetakan keadaan afektif ke dalam ruang dua dimensi kontinu, yakni *valence* yang direpresentasikan oleh sumbu horizontal atau derajat kenyamanan dari sangat tidak menyenangkan hingga sangat menyenangkan, dan *arousal* yang direpresentasikan oleh sumbu vertikal atau derajat aktivasi dari sangat tenang hingga sangat terstimulasi, dengan keadaan netral berada di titik pusat kedua sumbu. Representasi Russell's Circumplex Model of Affect ini dapat dilihat pada Gambar 2.



Gambar 2. Representasi Russell's Circumplex Model of Affect

Pemilihan *circumplex model*, alih-alih model kategorikal murni, dijustifikasi oleh tiga alasan teknis yang relevan langsung dengan arsitektur MoodIn:

1. Kesesuaian dengan sifat mood yang non-intensional dan difus. Sebagaimana sudah dijelaskan pada subbab sebelumnya, mood berbeda dari emosi karena tidak memiliki pemicu diskrit dan bertahan lebih lama secara difus. Model kategorikal dirancang untuk emosi episodik dengan pemicu jelas (misal "marah karena X"), sementara ruang kontinu valence–arousal lebih representatif untuk keadaan afektif yang bergeser gradual sepanjang hari, persis karakteristik yang ingin ditangkap MoodIn dari rutinitas bercermin harian.
2. Ketahanan terhadap *response inhibition*. Studi klinis oleh Ringgold dkk. [19] yang mengadaptasi protokol *Trier Social Stress Test* (TSST) menemukan bahwa manusia yang mengalami tekanan psikologis akut cenderung melakukan *response inhibition*, pembekuan ekspresi sebagai bentuk pertahanan diri, sehingga algoritma klasifikasi kategorikal berbasis label emosi dasar seperti marah dan takut gagal mengenali kondisi tertekan ini karena wajah tampak "netral" secara kasatmata. Namun, penurunan intensitas Action Unit spesifik (mis. AU12/senyum) tetap terukur secara kuantitatif dan bergeser posisinya dalam ruang valence–arousal, meski tidak cukup untuk dilabeli kategori emosi diskrit tertentu. Di MoodIn, argumen yang sama berlaku: representasi kontinu circumplex lebih tahan terhadap kegagalan deteksi akibat pembekuan ekspresi dibanding klasifikasi kategorikal yang kaku.

3. Kompatibilitas sebagai ruang fusi multimodal. Karena arousal berkorelasi dengan aktivasi sistem saraf otonom yang tercermin pada HRV/BRV hasil ekstraksi rPPG, sedangkan valence lebih dekat berkorelasi dengan geometri ekspresi wajah (Action Units), circumplex model menyediakan "sistem koordinat" bersama yang alami untuk menyatukan kedua modalitas: jalur fisiologis memberi kontribusi dominan pada sumbu arousal, jalur wajah memberi kontribusi dominan pada sumbu valence, dan keduanya difusikan pada tahap akhir menjadi satu titik dalam bidang valence–arousal.

Perlu ditegaskan bahwa titik pusat (0,0) pada Gambar 2 yakni kondisi netral, secara definisi bukan bagian dari keempat kuadran, melainkan region tersendiri. Oleh karena itu, MoodIn mengklasifikasikan mood ke dalam lima kelas keluaran, bukan empat label aktif yang diturunkan dari kuadran ruang valence–arousal dimana Q1 valence positif/arousal tinggi atau ceria; Q2 valence negatif/arousal tinggi atau cemas; Q3 valence negatif/arousal rendah atau tertekan; Q4 valence positif/arousal rendah atau rileks, ditambah satu kelas Netral yang merepresentasikan region di sekitar titik pusat tempat sinyal afektif tidak cukup menonjol untuk dikategorikan ke salah satu kuadran manapun.

Kelima kelas ini sengaja tidak diturunkan dari satu mekanisme yang sama. Empat label kuadran diturunkan dari regresi valence–arousal kontinu, konsisten dengan justifikasi poin 1 dan 2 di atas. Sementara itu, label Netral diwarisi langsung dari anotasi kategorikal "Neutral" yang telah tersedia secara *native* pada dataset FER standar seperti CK+, Oulu-CASIA, dan CAER [11], alih-alih diturunkan dari ambang jarak (*threshold*) terhadap titik pusat pada ruang valence–arousal. Pendekatan dua-sumber ini dipilih untuk menghindari isu *chattering*, ketidakstabilan label akibat derau sensor saat sinyal valence–arousal mendekati nol, sekaligus memungkinkan sistem membedakan secara eksplisit antara "wajah benar-benar tidak menunjukkan sinyal afektif" (Netral) dan "wajah menunjukkan sinyal afektif ringan yang condong ke salah satu kuadran" (empat label lainnya), perbedaan yang relevan secara klinis mengingat temuan *response inhibition* pada poin 2.

Justifikasi teknis di atas juga didukung oleh preseden pada literatur GCN untuk pengenalan ekspresi wajah. Antoniadis dkk. (2021) mengusulkan kerangka *multi-task learning* yang memakai GCN untuk secara eksplisit mempelajari ketergantungan (*dependencies*) antara model kategorikal dan model dimensional emosi sekaligus dalam satu representasi fitur bersama, dievaluasi pada dataset AffectNet dan Aff-Wild2, dan menunjukkan bahwa pendekatan gabungan ini mengungguli metode *state-of-the-art* pada pengenalan kategorikal murni [9]. Preseden inilah yang mendasari desain keluaran ganda (*dual-head*) pada arsitektur GCN MoodIn: satu *head* regresi untuk koordinat valence–arousal kontinu, dan satu *head*

klasifikasi 5-kelas (Ceria, Cemas, Tertekan, Rileks, Netral) yang dijelaskan lebih lanjut pada Subbab 2.5.

2.3. Ekspresi Wajah sebagai Representasi Mood

Dalam analisis ekspresi wajah, pendekatan yang banyak digunakan adalah Facial Action Coding System (FACS) yang mendekomposisikan ekspresi wajah sebagai unit-unit gerakan otot yang disebut Action Units (AU) [12]. Action Units merepresentasikan kontraksi atau relaksasi satu atau sekelompok otot wajah tertentu secara independen, sehingga kombinasi AU yang berbeda dapat membentuk berbagai ekspresi. Karakteristik inilah yang mendasari berbagai model generatif dan pengenalan ekspresi wajah terkini [13]. Hubungan antara AU dan mood terletak pada fakta bahwa kombinasi serta intensitas AU tertentu berkorelasi dengan dimensi afektif seperti valence dan arousal.

Tan dkk. [14] mengembangkan pendekatan yang secara eksplisit memetakan kemunculan dan intensitas AU ke dalam representasi emosi kontinu (emotion index) menggunakan convolutional neural network (CNN), dengan mendefinisikan dua kutub polaritas, yakni emosi positif dan negative, sebagai dasar pemetaan. Hasil penelitian mereka menunjukkan bahwa intensitas kombinasi AU tertentu dapat secara efektif merepresentasikan pergeseran mood dari waktu ke waktu, bukan hanya kategori emosi diskret seperti senang, sedih, atau marah, melainkan posisinya pada suatu spektrum kontinu yang selaras dengan dimensi valence.

Temuan ini diperkuat oleh Zhang dkk. [15], yang menunjukkan bahwa dinamika AU wajah yang diekstraksi secara otomatis dari rekaman video dapat digunakan untuk mengestimasi dinamika valence dan arousal secara berkelanjutan (kontinu terhadap waktu), dengan tingkat kesesuaian yang sebanding terhadap metode berbasis elektromiografi (EMG) wajah yang selama ini dianggap sebagai pendekatan fisiologis yang lebih presisi. Studi ini menegaskan bahwa AU tidak hanya mampu merepresentasikan kategori emosi secara statis, tetapi juga mampu menangkap perubahan intensitas mood dari waktu ke waktu, menjadikannya representasi yang relevan untuk pemantauan mood berkelanjutan.

Meski demikian, hubungan antara AU dan mood tidak selalu bersifat satu-ke-satu. Turrisi dkk. [16] menegaskan bahwa relasi antara AU dan status emosi umumnya bersifat many-to-many yang artinya satu AU dapat berkontribusi pada beberapa emosi berbeda, sementara satu emosi dapat direpresentasikan oleh berbagai kombinasi AU. Ambiguitas kontekstual ini semakin kompleks ketika mempertimbangkan intensitas dan kombinasi AU secara simultan, sehingga interpretasi mood berdasarkan AU memerlukan pertimbangan konteks tambahan agar inferensi afektif yang dihasilkan tetap akurat.

2.4. Remote Photoplethysmography (rPPG) untuk klasifikasi Mood

Salah satu metode standar pengukuran sinyal kardiovaskular adalah menggunakan *Photoplethysmography* (PPG) yang bekerja dengan memanfaatkan absorpsi cahaya pada kapiler kulit akibat fluktuasi volume darah [20]. Pendekatan PPG konvensional memerlukan sensor fisik yang digunakan di jari tangan sedangkan pendekatan rPPG hanya memerlukan kamera untuk menangkap perubahan warna yang diserap kulit wajah pengguna [21]. Hal tersebut memungkinkan dilakukannya analisis HRV dan BVP secara non kontak. rPPG dapat digunakan untuk pengenalan mood seseorang karena HRV dan BRV merupakan modulasi luaran sistem saraf otonom yang sama-sama dipengaruhi kondisi afektif. Casado dkk. [17] menunjukkan bahwa BVP dan fitur HRV yang diekstraksi murni dari video wajah mampu membedakan tingkat keparahan gejala depresi pada dua dataset benchmark klinis, dengan performa yang sebanding. Lebih dari 60 fitur statistik, geometris, dan fisiologis diekstraksi dari sinyal rPPG dalam studi tersebut, menegaskan bahwa perubahan pada respons kardiovaskular yang tertangkap lewat rPPG bukan sekadar artefak teknis, melainkan cerminan nyata dari kondisi mood yang mendasarinya.

Untuk mengekstraksi sinyal BVP dan metrik HRV secara *robust* dari video wajah, MoodIn mengadopsi arsitektur Spatiotemporal–Channel Feature Collaborative Learning (STC-rPPG) yang diusulkan Lin dkk. [10]. Arsitektur ini dirancang dengan pendekatan *Dual-Path Collaborative Learning* yang secara bersamaan menangkap dinamika spasial-temporal dan hubungan antar-kanal warna dari video wajah, didukung oleh modul *Facial Shallow Feature Extraction* (FSFE) dengan mekanisme *Global Context* (GC) *attention block* yang mengarahkan fokus jaringan secara otomatis pada area wajah kaya sinyal hemodinamika seperti pipi dan dahi, sekaligus menekan *noise* dari latar belakang [10]. Fitur spasial-temporal yang lebih halus kemudian diekstraksi melalui modul *Spatiotemporal Feature Extraction* (STFE) yang memanfaatkan koneksi residual untuk mencegah hilangnya informasi sinyal fisiologis mikroskopis akibat pergerakan kepala. Pada pengujian dataset PURE dan UBFC-rPPG, STC-rPPG tercatat mengungguli sebagian besar model estimasi detak jantung berbasis rPPG lainnya, dengan *Mean Absolute Error* (MAE) sebesar 0,23 bpm, ukuran model yang ringan (0,82 juta parameter), dan kecepatan inferensi hingga 20,40 *Frames Per Second* (FPS) [10], karakteristik yang menjadikannya sesuai untuk diimplementasikan pada perangkat *Edge AI* berdaya komputasi terbatas seperti Raspberry Pi yang digunakan MoodIn. Ketangguhan arsitektur ini terhadap fluktuasi pencahayaan dan artefak gerakan menjadi pertimbangan utama pemilihannya, mengingat MoodIn beroperasi di lingkungan bercermin dengan kondisi cahaya yang bervariasi sepanjang hari.

Pola serupa berlaku pada domain respirasi. Jerath dan Beveridge [18] dalam tinjauannya menegaskan bahwa spektrum pola napas berkorelasi dengan berbagai kondisi emosi, mulai dari kecemasan, depresi, kemarahan, hingga stres. Hubungan ini bersifat dua arah: mood memengaruhi pola napas, namun pola napas juga dapat memengaruhi mood melalui mekanisme umpan balik sistem saraf otonom, misalnya melalui respiratory sinus arrhythmia yang menghubungkan ritme napas dengan HRV. Dengan demikian, BRV bukan sekadar pelengkap teknis bagi HRV, melainkan indikator independen yang turut mencerminkan kondisi afektif seseorang.

2.5. Graph Convolutional Network untuk Klasifikasi Mood Multimodal

Graph Convolutional Network (GCN) dipilih sebagai tulang punggung jalur biomekanis MoodIn karena kemampuannya memodelkan wajah sebagai graf spasial-temporal, bukan sebagai piksel citra utuh, sehingga secara inheren melindungi privasi biometrik pengguna dan lebih tahan terhadap oklusi parsial maupun variasi pencahayaan dibanding pendekatan CNN konvensional berbasis *global appearance*.

Kerangka kerja Graph-Tran yang diusulkan Zhao dkk. menggabungkan *Spatial-Temporal Graph Convolutional Network* (ST-GCN) dengan modul Transformer berbasis panduan geometri, beroperasi hanya dengan mengekstraksi koordinat *Facial Landmarks* dan potongan citra kecil di sekitarnya, lalu mengubahnya menjadi graf spasial-temporal [11]. Lapisan GCN mempelajari korelasi lokal antar titik wajah yang berdekatan, sementara modul Transformer dengan mekanisme *multi-head self-attention* menemukan korelasi non-lokal jarak jauh, misalnya hubungan asimetris antara pergerakan alis dan sudut bibir. Arsitektur ini terbukti secara empiris jauh lebih tahan terhadap oklusi dan derau dibanding CNN konvensional pada pengujian dataset CK+, Oulu-CASIA, dan CAER [11]. MoodIn menggunakan arsitektur ini yang sudah mengadaptasi modul ST-GCN dan Transformer untuk mengekstraksi intensitas Action Unit. Pada MoodIn, arsitektur tersebut diperluas dengan menambahkan dua lapisan keluaran paralel di bagian akhir, pertama adalah *head* regresi linear yang memprediksi koordinat kontinu (valence, arousal), dan kedua yakni *head* klasifikasi 5-kelas yang memprediksi label kuadran atau Netral, sebagaimana dijustifikasi pada Subbab 2.2.

Sebagai pelengkap, Antoniadis dkk. menunjukkan secara spesifik bahwa GCN dapat dipakai untuk mempelajari ketergantungan eksplisit antara representasi kategorikal dan dimensional emosi dalam kerangka *multi-task learning*, dievaluasi pada dataset AffectNet dan Aff-Wild2 [9]. Preseden ini menjadi rujukan teknis untuk desain lapisan keluaran ganda pada arsitektur GCN MoodIn. Sebagaimana dicatat pada Subbab 2.2, implementasinya disesuaikan dengan graf berbasis landmark spasial, bukan graf semantik antar-label ala Antoniadis dkk.,

agar konsisten dengan basis kode ST-GCN yang sudah dimiliki tim. Perbedaan sumber label untuk kelima kelas turut memengaruhi desain fungsi *loss* pelatihan yang direncanakan: *loss* gabungan terdiri atas *mean squared error* atau *cosine similarity* untuk regresi valence–arousal pada empat kuadran aktif, dan *cross-entropy* untuk klasifikasi kategorikal 5-kelas yang turut memanfaatkan label "Neutral" bawaan dataset, sehingga kedua *head* saling melengkapi, bukan saling menggantikan.

Pada klasifikasi 5-kelas, lapisan output menerapkan fungsi aktivasi Softmax untuk mengubah logit menjadi distribusi probabilitas matematis $\mathrm{P(y = k|x)}$. Keputusan klasifikasi akhir kemudian ditentukan menggunakan fungsi Argmax, yaitu memilih kelas $\mathrm{k} \in$ {Ceria, Rileks, Cemas, Tertekan, Netral} yang memiliki nilai probabilitas posterior tertinggi $\hat{y} = \arg\max_k P(y = k|x)$.

2.6. Internet of things untuk Integrasi Sistem Wellness

Setelah klasifikasi mood dihasilkan pada perangkat edge Raspberry Pi 5, status mood beserta metadata ringkas, bukan citra wajah mentah, yang dikirimkan melalui protokol *publish-subscribe* ringan seperti MQTT menuju gateway IoT, sebagaimana digambarkan pada Tahap 6 alur sistem MoodIn pada Gambar 1. Pemilihan MQTT konsisten dengan kebutuhan *low-bandwidth* dan *low-latency* pada perangkat edge yang beroperasi kontinu di lingkungan rumah tangga. Data time-series hasil klasifikasi kemudian disimpan pada basis data *time-series* di cloud, misalnya InfluxDB atau TimescaleDB, untuk mendukung agregasi tren mood mingguan, yang selanjutnya diproses oleh mesin rekomendasi intervensi sederhana, sepertti *rule-based* atau *threshold-based* pada tahap awal, mengingat batasan proyek non-deep-learning untuk komponen ini, sebelum ditampilkan kembali ke pengguna melalui aplikasi smartphone dan tampilan biofeedback pada smart mirror. Arsitektur *edge-to-cloud* ini memastikan pemrosesan citra wajah yang sensitif tetap berada di perangkat lokal, sementara hanya hasil klasifikasi teragregasi yang dikirim ke cloud, pola yang sama dengan prinsip privasi-oleh-desain yang sudah diterapkan pada proyek Form B tim Anda.

BAB III
DESAIN PURWARUPA

3.1. Spesifikasi Prototipe

Tabel 1. berikut menunjukkan spesifikasi komponen yang digunakan pada MoodIn:

Tabel 1. Spesifikasi Komponen yang digunakan pada Sistem MoodIn

Komponen	Spesifikasi
Board Base	Raspberry Pi 5 16GB
Display	10.1-inch Capacitive Touch Screen LCD (E) Waveshare 1024x600 HDMI IPS 60 Hz
Mirror	Tempered Glass dilapisi Stiker Ruben
Power Voltage	5 Volt
Current Consumption	5 Ampere
USB Power	USB Type C (PD 3.0 compatible)
Camera Module	IMX708 NoIR (Raspberry Pi Camera Module 3 V3)
Field of View Camera	66° (Horizontal), 41° (Vertical), 75° (Diagonal)
Pencahayaan Tambahan	
Network	Wi-Fi 802.11ac / Bluetooth 5.0 BLE / Ethernet Gigabit.
Storage	MicroSD
Operating System	Debian Trixie
Network Interface	wlan0/eth0 (TCP/IP Stack) dengan protokol MQTT over TLS/SSL (Port 8883) dan HTTP/REST API
Main Program Script	Python 3.14 (runtime PyTorch / ONNX Runtime dan arsitektur Asynchronous Multiprocessing)
GUI Driver	EGL/OpenGL ES 3.1 (Wayland/Xwayland)
GUI Toolkit	PyQt6

Pemilihan setiap komponen pada Tabel 1 dilandasi oleh perhitungan kebutuhan komputasi, akuisisi sinyal, dan daya yang saling terkait dengan arsitektur sistem pada Subbab 2.1 dan 4.1.

a. Justifikasi Board Compute Raspberry Pi 5 16GB

Sistem MoodIn menjalankan dua model deep learning secara bersamaan, yakni STC-rPPG dan ST-GCN Graph-Tran, dalam skema *asynchronous multiprocessing* yang dapat dilihat pada Gambar 1 dan 4. Estimasi kebutuhan memori minimum dapat didekati dengan:

$$M_{\text{total}} = M_{STC} - rPPG + M_{ST\text{-}GCN} + M_{\text{buffer}} + M_{OS} \quad (1)$$

dengan $M_i$adalah alokasi memori model *i* (bobot + aktivasi runtime), M_{buffer} adalah alokasi *frame buffer* video dari kamera, dan M_{OS} adalah overhead sistem operasi Debian Trixie beserta PyQt6 GUI. Sebagai acuan kasar, STC-rPPG memiliki 0,82 juta parameter [10]. Pada presisi FP32:

$$M_{\text{weights}} = N_{\text{params}} \times B \quad (2)$$

dengan $N_{\text{params}} = 0{,}82 \times 10^6$dan B = 4 byte/parameter (FP32) atau 1 byte/parameter jika dikonversi ke INT8 pasca-kuantisasi ONNX Runtime. Bobot model itu sendiri sangat ringan (~3,3 MB FP32), namun beban dominan justru berasal dari M_{buffer} yakni buffer video multi-frame untuk jendela rPPG dan proses paralel dua *pipeline* sekaligus. Variansi RAM 16GB dipilih untuk memberi *headroom* menghindari *swap memory* yang akan menambah latensi inferensi, dibanding varian 8GB yang lebih rawan *out-of-memory* saat kedua model dan GUI berjalan bersamaan.

b. Justifikasi Modul Kamera IMX708 NoIR

Frame rate kamera harus memenuhi kriteria Nyquist agar mampu merekonstruksi denyut jantung dari sinyal rPPG tanpa *aliasing*:

$$f_s \geq 2 \cdot f_{\text{HR}}, max \quad (3)$$

dengan f_s = frame rate kamera (fps) dan f_HR,max = frekuensi detak jantung maksimum yang ingin ditangkap (Hz). Untuk rentang detak jantung manusia dewasa saat kondisi tenang hingga sedikit tertekan (40–180 bpm):

$$f_{HR}, max = \frac{180\ bpm}{60} = 3Hz \quad (4)$$

$$\rightarrow\ f_s \geq 2 \times 3\ Hz = 6\ fps\ (syarat\ minimum)$$

Kamera IMX708 pada mode standar mampu beroperasi hingga 30–56 fps tergantung resolusi yang dipakai, jauh melampaui syarat minimum tersebut. *Headroom* ini penting karena STC-rPPG sendiri diuji pada kecepatan inferensi 20,40 FPS [10], sehingga frame rate akuisisi perlu mengimbangi kecepatan inferensi tanpa menjadi *bottleneck* pipeline.

Selain frame rate, estimasi HRV yang andal, khususnya komponen domain-frekuensi seperti *high-frequency power* membutuhkan panjang jendela sinyal minimum. Mengacu pada konvensi umum literatur HRV dengan durasi rekaman jangka pendek ≥ 30 detik untuk analisis frekuensi yang stabil:

$$N_{frame} = f_s \times T_{window} \quad (5)$$

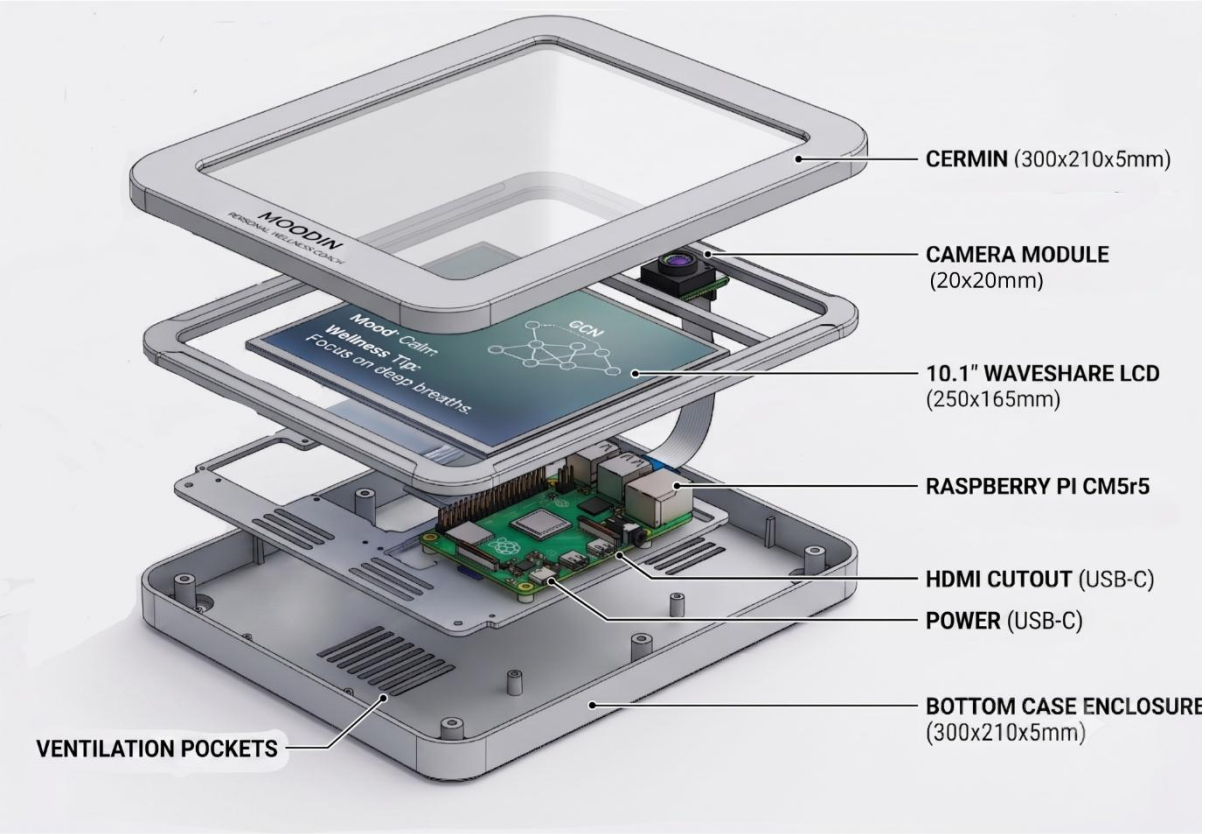
dengan $T_{window} \geq 30$ detik. Pada f_s = 30 fps, maka $N_{frame} \geq 900$ frame per jendela analisis, nilai ini yang menentukan ukuran M_buffer pada Persamaan (3.1) dan durasi *delay* sebelum klasifikasi mood pertama dapat dihasilkan setelah pengguna berdiri di depan cermin.

Alasan pemilihan varian NoIR atau tanpa filter infrared-cut adalah agar sensor tetap sensitif terhadap variasi spektral halus pada permukaan kulit yang menjadi dasar sinyal rPPG, karena filter IR-cut pada kamera standar dirancang justru untuk menekan komponen spektral inilah demi akurasi warna visual yang kontraproduktif untuk kebutuhan MoodIn.

[ISI]: Sertakan juga field of view (FoV) aktual modul kamera (mis. 66°/102° tergantung varian lensa) sebagai baris tambahan di Tabel 1, nilai ini akan dipakai pada Persamaan (7) di Subbab 3.2.

3.2. Model 3D Desain

Desain purwarupa MoodIn pada Gambar 3 disusun dalam empat lapisan fungsional: lapisan cermin (interaksi optik), lapisan layar (interaksi visual/UI), lapisan komputasi (Raspberry Pi 5), dan lapisan enclosure bawah (manajemen termal dan proteksi). Setiap lapisan memiliki pertimbangan teknis sebagai berikut.



Gambar 3. Desain 3D Model Alat MoodIn

1) Trade-off Cermin Dua-Arah terhadap Sinyal rPPG

Penempatan kamera tersembunyi di balik cermin dua-arah menimbulkan atenuasi cahaya yang berdampak langsung pada kualitas sinyal rPPG. Transmisi cahaya melalui material cermin dapat dimodelkan secara sederhana sebagai:

$$I_t = T \cdot I_0 \tag{6}$$

dengan I_0 = intensitas cahaya datang, T = koefisien transmitansi cermin dengan tipikal *two-way mirror* akrilik berkisar 30–50%, dan I_t = intensitas cahaya yang benar-benar mencapai sensor kamera.

Karena sistem pencitraan digital pada kondisi cahaya terbatas umumnya berada pada rezim *photon shot-noise-limited* dimana derau meningkat sebanding dengan akar jumlah foton

yang tertangkap, sementara sinyal meningkat linear terhadap jumlah foton, degradasi SNR akibat atenuasi cermin dapat didekati dengan:

$$\frac{SNR_{cermin}}{SNR_{terbuka}} \approx \sqrt{T} \quad (7)$$

Sebagai ilustrasi, pada T = 0,4 (40%), SNR sinyal rPPG turun menjadi sekitar √0,4 ≈ 63% dari kondisi tanpa cermin, signifikan mengingat komponen AC sinyal BVP dari kulit wajah secara alami sudah sangat kecil (~1–2% dari intensitas DC). Ini menjadi dasar teknis untuk dua opsi mitigasi desain yang perlu diputuskan tim: **(a)** menambahkan pencahayaan suplemen terkontrol (misal LED ring near-IR redup) di sekitar lubang kamera untuk menaikkan I_0 efektif, atau **(b)** memilih material cermin dengan T lebih tinggi pada area tepat di depan lensa kamera (mis. lubang kecil berlapis film transmitansi tinggi, bukan area cermin utuh).

[ISI]: Jika tim sudah melakukan pengujian nyata (bandingkan amplitudo sinyal BVP hasil ekstraksi ROI dahi/pipi dengan dan tanpa cermin), cantumkan hasil ukurnya di sini sebagai validasi empiris terhadap Persamaan (7), ini akan sangat memperkuat kredibilitas Bab 3.3.

2) Manajemen Termal Enclosure

Raspberry Pi 5 memiliki *Thermal Design Power* signifikan yakni, SoC dapat mengalami *thermal throttling* di sekitar 85°C tanpa pendinginan memadai, saat menjalankan inferensi deep learning kontinu. Secara sederhana, hampir seluruh daya listrik yang dikonsumsi dikonversi menjadi panas:

$$Q_{disipasi} \approx P_{total} \quad (8)$$

Ventilation pockets pada bagian bawah *enclosure* pada Gambar 3 berfungsi sebagai jalur konveksi pasif untuk membuang $Q_{disipasi}$ ke lingkungan, mencegah akumulasi panas dalam ruang tertutup yang dapat memicu *thermal throttling* dan menurunkan kecepatan inferensi FPS secara tidak terduga di lapangan.

[ISI]: Sebutkan apakah desain memakai heatsink pasif tambahan atau kipas aktif kecil, karena ini memengaruhi tebal *enclosure bottom case* dan perlu konsisten dengan dimensi 300x210x5mm pada Gambar 3.

3) Geometri Penempatan Kamera terhadap Jarak Bercermin

Agar seluruh wajah pengguna tertangkap secara konsisten dalam jarak bercermin yang wajar yang umumnya 30–60 cm dari cermin kamar mandi/kamar tidur, lebar area yang tertangkap kamera pada jarak tertentu dapat dihitung dengan:

$$w = 2 \cdot d \cdot tan\left(\frac{FoV}{2}\right) \quad (9)$$

dengan d = jarak pengguna ke kamera, FoV = sudut pandang horizontal lensa (lihat catatan **[ISI]** pada Persamaan 3.3), dan w = lebar area tertangkap pada jarak d. Perhitungan ini berguna

untuk memastikan bahwa pada jarak minimum dan maksimum penggunaan wajar, wajah pengguna tetap berada penuh dalam bidang pandang tanpa terpotong, parameter penting untuk keandalan ekstraksi 468 *face landmarks* MediaPipe pada Subbab 2.5.

3.3. Prototipe Progres

Karena bagian ini menuntut bukti progres konkret, bukan rencana, saya sarankan strukturnya memuat metrik terukur berikut alih-alih narasi kualitatif semata.

a. Formula Pelacakan Progres Tertimbang

Untuk merangkum status pengerjaan multi-komponen (hardware, dua model deep learning, UI) menjadi satu indikator progres keseluruhan yang objektif, gunakan skema *weighted progress*:

$$P_{total} = \frac{\Sigma\, w_i \cdot p_i}{\Sigma\, w_i} \tag{10}$$

dengan w_i = bobot kepentingan/kompleksitas komponen i, misal berdasarkan estimasi jam kerja, dan $p_i \in [0,1]$ = persentase penyelesaian komponen tersebut. Ini memungkinkan tim menunjukkan angka progres tunggal yang defensible di tabel status, alih-alih klaim persentase yang terkesan subjektif.

b. Metrik Evaluasi yang Direncanakan untuk Setiap Model

Sebutkan metrik ini di Subbab 3.3 sebagai bagian dari "target validasi awal", bahkan sebelum hasil akhir tersedia, ini menunjukkan kematangan rencana pengujian kepada evaluator.

Untuk model STC-rPPG (estimasi detak jantung):

$$MAE = \left(\frac{1}{N}\right) \cdot \Sigma \left| HR_{pred}, i - HR_{true}, i \right| \tag{11}$$

sebagai metrik pembanding langsung terhadap hasil acuan MAE = 0,23 bpm yang dilaporkan Lin dkk. [10] pada dataset PURE dan UBFC-rPPG.

Untuk head klasifikasi 5-kelas mood:

$$Accuracy = \frac{Jumlah\ prediksi\ benar}{Jumlah\ total\ sampel} \tag{12}$$

Mengingat potensi ketidakseimbangan kelas, misalnya kelas Netral cenderung lebih dominan dalam dataset FER dibanding kelas afektif ekstrem, sebaiknya dilengkapi metrik F1-score per kelas dan confusion matrix, bukan akurasi tunggal, agar performa pada kelas minoritas, misalnya Tertekan/Cemas yang justru kelas paling krusial secara klinis, tidak tersamarkan oleh akurasi rata-rata yang tinggi.

Untuk head regresi valence–arousal menggunakan Concordance Correlation Coefficient (CCC):

$$CCC = \frac{2 \cdot \rho \cdot \sigma_{pred} \cdot \sigma_{true}}{\sigma_{pred}^2 + \sigma_{true}^2 + (\mu_{pred} - \mu_{true})^2} \quad (13)$$

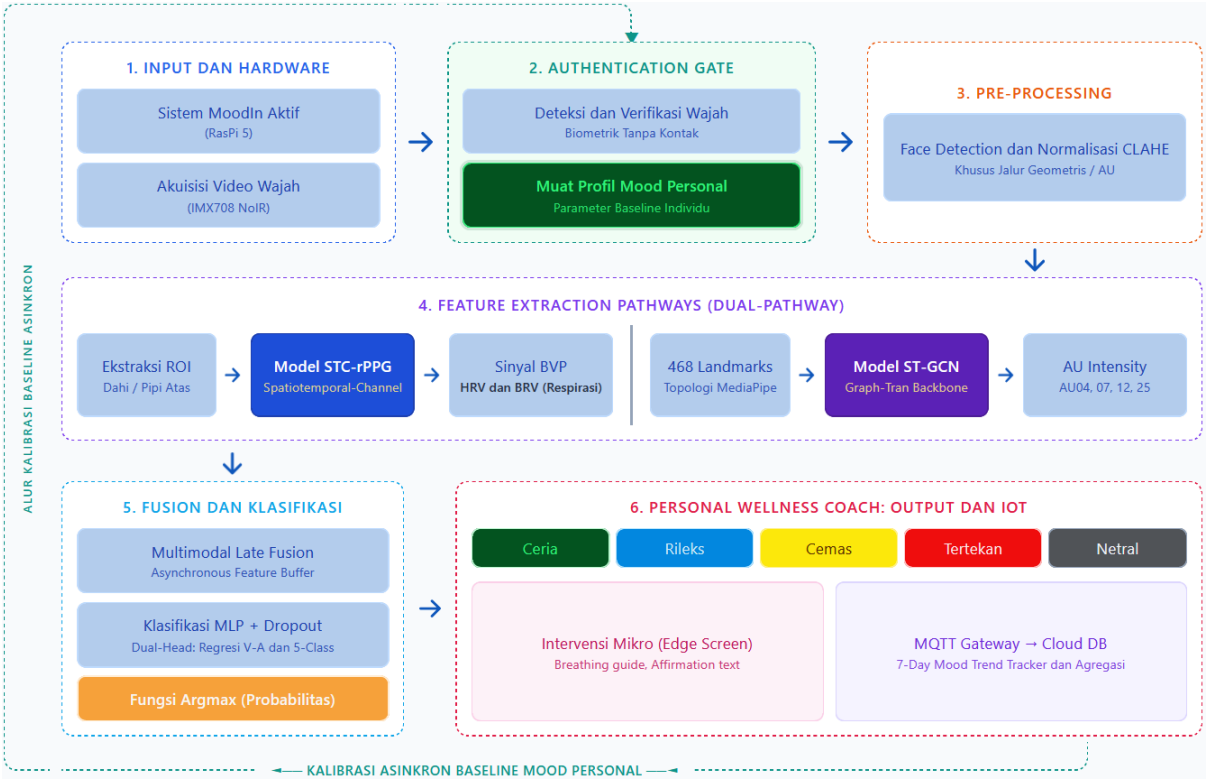
dengan ρ = koefisien korelasi Pearson antara prediksi dan ground truth, σ = simpangan baku, dan μ = rata-rata masing-masing distribusi. CCC dipilih sebagai metrik utama bukan sekadar RMSE karena merupakan standar evaluasi de facto pada benchmark valence-arousal seperti AffectNet dan Aff-Wild2 yang juga dipakai Antoniadis dkk. [9], konsisten dengan preseden teknis yang sudah dirujuk di Subbab 2.5, sekaligus menunjukkan koherensi metodologis antara justifikasi arsitektur dan rencana evaluasinya.

c. Struktur Penulisan yang Disarankan untuk 3.3

Dengan kerangka di atas, Subbab 3.3 idealnya berisi: **(a)** tabel status implementasi per komponen dengan p_i terisi (bisa dihitung P_total pakai Persamaan 10), **(b)** dokumentasi visual progres aktual (foto casing, screenshot landmark detection real-time, dsb.), **(c)** kendala teknis yang sudah ditemukan (misalnya hasil awal Persamaan 7 soal atenuasi cermin, jika sudah diuji), dan **(d)** rencana metrik evaluasi (Persamaan 11–13) sebagai penutup yang menjembatani ke Bab 4.4 (Kinerja/Performansi) yang saat ini juga masih kosong di proposal.

BAB IV
ANALISIS FUNGSIONAL

4.1. Prinsip Kerja Sistem



Gambar 4. Alur Kerja MoodIn

4.2. Analisis Fungsional

[based on proposal taun kemaren, di bagian ini itu pengujian komponen, kek sensor/kamera begitu. Cuman ga yakin sih aku memang kek gini atau gimana hhhhh. Gpt ➔ interaksi user dan sistem, bisa pakai use case diagram juga]

Secara fungsional, sistem MoodIn dirancang sebagai *smart mirror* yang mampu mengenali dan mengklasifikasikan kondisi mood harian pengguna secara *contactless*, kemudian memberikan umpan balik preventif berbasis hasil klasifikasi tersebut. Sistem menjalankan lima fungsi utama.

1. Fungsi autentikasi dan personalisasi, di mana sistem melakukan deteksi dan verifikasi wajah pengguna terlebih dahulu sebelum memuat profil mood personal yang bersangkutan, sehingga hasil klasifikasi dan rekomendasi yang diberikan bersifat individual dan kontekstual terhadap riwayat masing-masing pengguna.

2. Fungsi akuisisi dan pra-pemrosesan citra wajah, yang mencakup deteksi wajah serta normalisasi kondisi pencahayaan agar kualitas sinyal yang diekstraksi pada tahap berikutnya tetap stabil.
3. Fungsi ekstraksi fitur ganda (*dual-pathway feature extraction*), yaitu ekstraksi fitur ekspresi wajah berbasis graf dan ekstraksi sinyal fisiologis dari video wajah tanpa kontak fisik.
4. Fungsi fusi multimodal dan klasifikasi, yang menggabungkan kedua jenis fitur tersebut untuk menghasilkan satu keputusan akhir berupa kategori mood pengguna.
5. Fungsi keluaran sebagai *personal wellness coach*, yang menyajikan hasil klasifikasi mood kepada pengguna disertai *micro-intervention* yang relevan serta menyediakan pelacakan tren mood selama tujuh hari terakhir sebagai bentuk pemantauan berkelanjutan.

4.3. Alur Kerja Sistem

4.4. Kinerja/Performansi

BAB V
RENCANA IMPLEMENTASI DAN PERKEMBANGAN PENGERJAAN

5.1. Tahapan Implementasi

Rencana implementasi MoodIn disusun secara sistematis untuk memastikan integrasi yang mulus antara perangkat keras *smart mirror,* pemrosesan sinyal biomedis, dan *model deep learning.* Tahapan utama dalam pengembangan ini meliputi:

1. Perakitan dan Pemodelan Perangkat Keras (*Hardware*)

   Tahap awal difokuskan pada perakitan purwarupa fisik *smart mirror* menggunakan *two-way acrylic/glass* yang dipadukan dengan panel monitor LCD. Modul kamera diintegrasikan secara tersembunyi di balik kaca dan dihubungkan ke Raspberry Pi 5 sebagai pusat komputasi utama (*edge device).* Desain dan tata letak elektronik dirancang agar ergonomis dan aman untuk penggunaan harian.

2. Pengembangan *Pipeline* Ekstraksi Fitur Multimodal

   Mengembangkan skrip akuisisi data berbasis Python untuk menangkap aliran video secara real-time. *Pipeline* ini dibagi menjadi dua jalur ekstraksi:

   d. Ekstraksi Spasial Wajah

      Mengimplementasikan pustaka MediaPipe untuk mendeteksi 468 *face landmarks* dan mengekstrak matriks topologi wajah.

   e. Ekstraksi Fisiologis (rPPG)

      Membangun algoritma pemrosesan sinyal dan *filtering* untuk mengisolasi *Region of Interest* (ROI) pada area dahi dan pipi, guna mendapatkan estimasi sinyal *Blood Volume Pulse* (BVP) dan kalkulasi *Heart Rate Variability* (HRV) yang bersih dari *noise* pencahayaan lingkungan.

3. Pelatihan dan Integrasi Model *Deep Learning*

   Membangun dan melatih arsitektur model menggunakan *framework* PyTorch. Model ST-GCN (*Spatial-Temporal Graph Convolutional Network*) dilatih untuk mengklasifikasi intensitas *Action Unit* (AU) dari data *landmarks*. Secara paralel, model STC-rPPG dilatih untuk memvalidasi ekstraksi sinyal otonom. Kedua *output* model kemudian digabungkan melalui mekanisme *Feature Fusion* untuk mengklasifikasikan mood (Ceria, Rileks, Cemas, Tertekan, Netral) secara probabilitas (argmax). Setelah dievaluasi, model akan dikonversi ke format yang ringan agar inferensi di Raspberry Pi 5 berjalan dengan latensi rendah.

4. Pengembangan Antarmuka Pengguna dan Intervensi Mikro

Merancang *User Interface* (UI) interaktif dan dashboard personalisasi terlebih dahulu menggunakan Figma untuk memastikan navigasi visual yang intuitif. Antarmuka ini kemudian diimplementasikan menggunakan *framework* yang responsif. Ketika mood pengguna terdeteksi (misalnya: Cemas atau Tertekan), sistem diprogram untuk memicu output intervensi mikro berupa teks afirmasi, visualisasi panduan pernapasan (*breathing exercise*), atau rekomendasi relaksasi di layar cermin.

5. Pengembangan Sistem Database dan Profiling

   Mengonfigurasi sistem basis data lokal pada *microcomputer* untuk mencatat profil pengguna secara anonim, riwayat deteksi mood harian, dan respons terhadap intervensi mikro. Manajemen data ini penting untuk menjaga privasi pengguna sekaligus memberikan laporan tren *wellness* (kesejahteraan mental) yang berkelanjutan.

6. Pengujian Lapangan (*Field Testing*) dan Kalibrasi

   Melakukan uji coba komprehensif pada purwarupa dalam kondisi pencahayaan yang bervariasi (pagi, siang, malam) untuk menguji keandalan sensor kamera dan algoritma rPPG. Evaluasi dilakukan terhadap akurasi klasifikasi mood, kecepatan respons layar, serta penerimaan pengguna terhadap bentuk intervensi mikro yang disajikan.

5.2 Lokasi Implementasi Awal

Sebagai Personal Wellness Coach, implementasi tahap awal dari alat MoodIn difokuskan pada lingkungan dengan tingkat kerentanan stres yang cukup terukur, meliputi:

1. Kamar Asrama Mahasiswa: Sebagai ruang personal (privat) untuk memantau tingkat stres akademik harian dan memberikan afirmasi pagi sebelum memulai aktivitas.
2. Ruang Konseling Kampus/Sekolah: Sebagai alat bantu skrining awal bagi konselor untuk melihat tren emosi mahasiswa atau siswa sebelum sesi konsultasi dimulai.
3. Fasilitas Kesehatan Primer (Klinik Psikologi): Diaplikasikan pada ruang tunggu pasien untuk membantu memberikan relaksasi mikro (seperti panduan tarik napas) selagi menunggu giliran, sekaligus merekam baseline mood awal pasien.

DAFTAR PUSTAKA

[1] Kementerian Kesehatan RI, Badan Kebijakan Pembangunan Kesehatan, "Depresi pada Anak Muda di Indonesia," Factsheet Survei Kesehatan Indonesia (SKI) 2023. [Online]. Tersedia: https://repository.badankebijakan.kemkes.go.id/id/eprint/5532/1/03%20factsheet%20Keswa_bahasa.pdf. [Diakses 7 Juli 2025]

[2] Badan Kebijakan Pembangunan Kesehatan (BKPK) Kemenkes RI, "Potret Sehat Indonesia dari Kacamata SKI 2023," 2024. [Online]. Tersedia: https://www.badankebijakan.kemkes.go.id/potret-sehat-indonesia-dari-kacamata-ski-2023/. [Diakses 7 Juli 2025]

[3] A. Z. Zhafirah dan S. P. Hastono, "Analisis Disparitas Geospasial dan Determinan Sosio-Demografis Masalah Kesehatan Jiwa di Indonesia: Analisis Data Survei Kesehatan Indonesia (SKI) 2023," ScholarHub UI, BIKFOKES, vol. 6, no. 2, 2025. [Online]. Tersedia: https://scholarhub.ui.ac.id/bikfokes/vol6/iss2/1/. [Diakses 7 Juli 2025]

[4] ANTARA News, "Pencarian Google Indonesia soal kesehatan meningkat selama pandemi," 23 Feb. 2021. [Online]. Tersedia: https://www.antaranews.com/berita/2014332/pencarian-google-indonesia-soal-kesehatan-meningkat-selama-pandemi. [Diakses 7 Juli 2025]

[5] U. K. Hisan, M. M. Amri, D. Sulisworo, I. Rahmawati, T. A. Pramesti, "Google Trends Potential for Detecting a Large-scale Mental Health Issue: A Study during Pandemic in Indonesia," Jurnal Aisyah: Jurnal Ilmu Kesehatan, 2023.

[6] S. Shiffman, A. A. Stone, dan M. R. Hufford, "Ecological Momentary Assessment," Annual Review of Clinical Psychology, vol. 4, pp. 1–32, 2008.

[7] J. Asselbergs, J. Ruwaard, M. Ejdys, N. Schrader, M. Sijbrandij, dan H. Riper, "Mobile Phone-Based Unobtrusive Ecological Momentary Assessment of Day-to-Day Mood: An Explorative Study," *Journal of Medical Internet Research*, vol. 18, no. 3, p. e72, 2016, doi: 10.2196/jmir.5505.

[8] J. A. Russell, "A Circumplex Model of Affect," Journal of Personality and Social Psychology, vol. 39, no. 6, pp. 1161–1178, 1980.

[9] P. Antoniadis, P. P. Filntisis, dan P. Maragos, "Exploiting Emotional Dependencies with Graph Convolutional Networks for Facial Expression Recognition," in Proc. IEEE Int. Conf. Automatic Face and Gesture Recognition (FG), 2021. arXiv:2106.03487.

[10] L. Lin, L. Wang, Y. Zhang, X. Li, A. Wen, J. Yan, L. Shi, W. Zhou, dan Y. Zhou. STC-rPPG: A Remote Heart Rate Estimation Network Based on Spatiotemporal–Channel Feature Collaborative Learning. IEEE Transactions on Instrumentation and Measurement. 2025;74:4017910.

[11] R. Zhao, T. Liu, Z. Huang, D. P. K. Lun, dan K. M. Lam, "Spatial-Temporal Graphs Plus Transformers for Geometry-Guided Facial Expression Recognition," IEEE Transactions on Affective Computing, vol. 14, no. 4, pp. 2751–2767, 2023.

[12] E. A. Clark, J. Kessinger, S. E. Duncan, M. A. Bell, J. Lahne, D. L. Gallagher, and S. F. O'Keefe, "The facial action coding system for characterization of human affective response to consumer product-based stimuli: A systematic review," Frontiers in Psychology, vol. 11, p. 920, 2020.

[13] M. Wei, T. Varanka, X. Jiang, H. Q. Khor, and G. Zhao, "MagicFace: High-fidelity facial expression editing with action-unit control," arXiv preprint arXiv:2501.02260, 2025.

[14] X. Tan, Y. Fan, M. Sun, M. Zhuang, and F. Qu, "An emotion index estimation based on facial action unit prediction," *Pattern Recognition Letters*, vol. 164, pp. 191–199, Dec. 2022, doi: 10.1016/j.patrec.2022.11.008.

[15] J. Zhang, W. Sato, N. Kawamura, K. Shimokawa, B. Tang, and Y. Nakamura, "Sensing emotional valence and arousal dynamics through automated facial action unit analysis," *Scientific Reports*, vol. 14, art. no. 19563, Aug. 2024, doi: 10.1038/s41598-024-70563-8.

[16] R. Turrisi, S. Iacono Isidoro, R. Bruschetta, F. Famà, A. Campisi, S. Aiello, G. Cusimano, L. Ruta, G. Pioggia, and G. Tartarisco, "Blendshape features meet action units: a clinical mapping for enhancing facial expression analysis," *Computers in Biology and Medicine Update* (ScienceDirect), 2026 (in press), doi: [belum terverifikasi].

[17] C. Álvarez Casado, M. Lage Cañellas, and M. Bordallo López, "Depression Recognition Using Remote Photoplethysmography From Facial Videos," *IEEE Transactions on Affective Computing*, vol. 14, no. 4, pp. 3305–3316, Oct.–Dec. 2023, doi: 10.1109/TAFFC.2023.3238641.

[18] R. Jerath and C. Beveridge, "Respiratory Rhythm, Autonomic Modulation, and the Spectrum of Emotions: The Future of Emotion Recognition and Modulation," *Frontiers in Psychology*, vol. 11, art. no. 1980, Aug. 2020, doi: 10.3389/fpsyg.2020.01980.

[19] V. Ringgold, F. Burkhardt, L. Abel, M. Kurz, V. Müller, R. Richer, dkk., "Multimodal stress assessment: Connecting task-related changes in self-reported stress, salivary biomarkers, heart rate, and facial expressions in the context of the stress response to the Trier Social Stress Test," *Psychoneuroendocrinology*, vol. 180, p. 107560, 2025.

[20] H. W. Loh dkk., "Application of photoplethysmography signals for healthcare systems: An in-depth review," *Computers in Biology and Medicine*, vol. 145, art. 105430, 2022.
[21] Paper H. Xiao (2024)

LAMPIRAN